공개형 데이터 설명서

- 폐암 · 유방암 · 대장암 합성 데이터 -

2023. 07. 01.

국립암센터 NATIONAL CANCER CENTER

국가암데이터센터 National Cancer Data Center

□ 개요 : 암임상 라이브러리 합성데이터(폐암·대장암·유방암)

○ 인공지능 기술의 비약적인 발전으로 인해 사회적·국가적 투자가 전략적으로 이루어지고 있으며, 국내에서도 임상데이터 기반 인공지능 기술의 선도적인 거점 확보를 위해 많은 연구 투자가 진행되고 있으나, 원천데이터 사용의 제약성으로 인해 개방 및 활용성이 매우 미비함

○ 이들 문제 해결위해 GAN(generative adversarial network)을 적용하여 생성한 **가상 데이터**인 **폐암·대장암·유방암 합성데이터**를 개방함으로써 인공지능 기술개발 활성화 및 확인을 기대함

□ 데이터 구성

○ 유방암 합성 데이터의 경우, 암등록, 건강정보, 신체계측정보, BRCA, 면역병리, 수술정보, 항암제치료 등 총 58개의 변수로 구성되었으며, 대장암 합성 데이터는 암 등록, 건강정보, 신체계측정보, 면역병리, 분자병리, 수술여부, 항암제치료 등의 52개변수로 구성되었으며, 폐암은 암 등록, 건강정보, 신체계측정보, 폐 기능 검사, 분자병리, 수술 여부, 치료 등의 32개 변수로 구성되어 있음.

데이터명	구분	데이터수	변수
유방암 합성데이터	훈련데이터	10,000	58
	테스트데이터	5,000	58
대장암 합성데이터	훈련데이터	10,000	52
	테스트데이터	5,000	52
폐암 합성데이터	훈련데이터	10,000	32
	테스트데이터	5,000	32

○ 유방암 합성데이터 코드북

NO.	중분류	변수명	변수 설명	변수값(코드) 설명 (99=모름/기타/미측정)	데이터 유형
0	기본정보	AGE	진단시연령	45	관찰입력 정보
1	암등록	inductal carcinoma	조직학적진단명 코드 설명	0=아니오, 1=예	관찰입력 정보
2	암등록	infiltrating duct carcinoma	조직학적진단명 코드 설명	0=아니오, 1=예	관찰입력 정보
3	암등록	adenocarcinoma	조직학적진단명 코드 설명	0=아니오, 1=예	관찰입력 정보
4	암등록	lobular carcinoma	조직학적진단명 코드 설명	0=아니오, 1=예	관찰입력 정보
5	암등록	Metaplastic carcinoma	조직학적진단명 코드 설명	0=아니오, 1=예	관찰입력 정보
6	암등록	TX	병기STAGE	0=아니오, 1=예	관찰입력 정보
7	암등록	T0	병기STAGE	0=아니오, 1=예	관찰입력 정보
8	암등록	T1	병기STAGE	0=아니오, 1=예	관찰입력 정보
9	암등록	T1mi	병기STAGE	0=아니오, 1=예	관찰입력 정보
10	암등록	T1a	병기STAGE	0=아니오, 1=예	관찰입력 정보
11	암등록	T1b	병기STAGE	0=아니오, 1=예	관찰입력 정보

12	암등록	T1c	병기STAGE	0=아니오, 1=예	관찰입력 정보
13	암등록	T2	병기STAGE	0=아니오, 1=예	관찰입력 정보
14	암등록	T2a	병기STAGE	0=아니오, 1=예	관찰입력 정보
15	암등록	T2b	병기STAGE	0=아니오, 1=예	관찰입력 정보
16	암등록	T3	병기STAGE	0=아니오, 1=예	관찰입력 정보
17	암등록	T4	병기STAGE	0=아니오, 1=예	관찰입력 정보
18	암등록	Nx	병기STAGE	0=아니오, 1=예	관찰입력 정보
19	암등록	N1mi	병기STAGE	0=아니오, 1=예	관찰입력 정보
20	암등록	N1	병기STAGE	0=아니오, 1=예	관찰입력 정보
21	암등록	N1a	병기STAGE	0=아니오, 1=예	관찰입력 정보
22	암등록	N1b	병기STAGE	0=아니오, 1=예	관찰입력 정보
23	암등록	N1c	병기STAGE	0=아니오, 1=예	관찰입력 정보
24	암등록	N2	병기STAGE	0=아니오, 1=예	관찰입력 정보

25	암등록	N2a	병기STAGE	0=아니오, 1=예	관찰입력 정보
26	암등록	N2b	병기STAGE	0=아니오, 1=예	관찰입력 정보
27	암등록	N3	병기STAGE	0=아니오, 1=예	관찰입력 정보
28	암등록	N3a	병기STAGE	0=아니오, 1=예	관찰입력 정보
29	암등록	N3b	병기STAGE	0=아니오, 1=예	관찰입력 정보
30	암등록	N3c	병기STAGE	0=아니오, 1=예	관찰입력 정보
31	암등록	M1	병기STAGE	0=아니오, 1=예	관찰입력 정보
32	암등록	M1a	병기STAGE	0=아니오, 1=예	관찰입력 정보
33	암등록	M1b	병기STAGE	0=아니오, 1=예	관찰입력 정보
34	건강정보	Type of Drink	음주종류	0=맥주, 1=소주, 2=양주, 99=기타	관찰입력 정보
35	건강정보	Smoke	흡연여부	0=비흡연, 1=현재흡연, 2=과거흡연	관찰입력 정보
36	건강정보	Age of Menarch	초경연령	16, 99= 무응답	관찰입력 정보
37	건강정보	Age of Menopause	폐경연령	55, 99= 무응답	관찰입력 정보

38	건강정보	Marriage	결혼여부	0=아니오, 1=예, 99= 무응답	관찰입력 정보
39	건강정보	Age at first birth	첫출산연령	20, 99= 해당사항 없음	관찰입력 정보
40	건강정보	Number of births	출산자녀수	3, 99= 해당사항 없음	관찰입력 정보
41	건강정보	COCP	경구피임약사용여부	0=아니오, 1=예, 99= 무응답	관찰입력 정보
42	건강정보	HRT	HRT 사용여부	0=아니오, 1=예, 99= 무응답	관찰입력 정보
43	신체계측 정보	Height	신장값	158	관찰입력 정보
44	신체계측 정보	Weight	체중측정값	58	관찰입력 정보
45	BRCA1	BRCA1 PVs	BRCA1 병원변형체 검출 여부	1=detected, 2=not detected, 99 = 해당사항 없음	관찰입력 정보
46	BRCA1	BRCA1 VUS	BRCA1 미확인변이 검출 여부	1=detected, 2=not detected, 99 = 해당사항 없음	관찰입력 정보
47	BRCA2	BRCA2 PVs	BRCA2 병원변형체 검출 여부	1=detected, 2=not detected, 99 = 해당사항 없음	관찰입력 정보
48	BRCA2	BRCA2 VUS	BRCA2 미확인변이 검출 여부	1=detected, 2=not detected, 99 = 해당사항 없음	관찰입력 정보
49	면역병리	ER	면역병리ER 검사결과코드	1=detected, 2=not detected, 99 = 해당사항 없음	관찰입력 정보
50	면역병리	PR	면역병리PR 검사결과코드	1=detected, 2=not detected, 99 = 해당사항 없음	관찰입력 정보

51	면역병리	AR	면역병리AR 검사결과코드	1=detected, 2=not detected, 9 = 해당사항 없음, 99 = 해당사항 없음	관찰입력 정보
52	수술정보	BCS	유방보전적 절제술여부 BCS	0=아니오, 1=예, 99= 해당사항 없음	관찰입력 정보
53	수술정보	Mestectomy	유방전절제술여부	0=아니오, 1=예, 99= 해당사항 없음	관찰입력 정보
54	자궁난소 수술정보	pan hysterosalpingo oophorectomy	양측난관난소 절제술여부	0=아니오, 1=예	관찰입력 정보
55	항암제치료	Chemotherapy	항암치료여부	0=아니오, 1=예	관찰입력 정보
56	호르몬치료	Hormone therapy	호르몬치료여부	0=아니오, 1=예	관찰입력 정보
57	방사선치료	Radiation Therapy	방사선치료여부	0=아니오, 1=예	관찰입력 정보
58	기본정보	Death	사망여부	0=아니오, 1=예	관찰입력 정보
59	기본정보	Survival period	암진단후생존일수	267 (days)	관찰입력 정보

○ 대장암 합성데이터 코드북

NO.	중분류	변수명	변수 설명	변수값(코드) 설명 (99=모름/기타/미측정)	데이터 유형
0	기본정보	AGE	진단시 연령	67	관찰입력 정보
1	암등록	mucinous	조직학적진단명 코드 설명	0=아니오, 1=예	관찰입력 정보
2	암등록	signet ring cell	조직학적진단명 코드 설명	0=아니오, 1=예	관찰입력 정보
3	암등록	adenocarcino ma	조직학적진단명 코드 설명	0=아니오, 1=예	관찰입력 정보
4	암등록	carcinoide tumor	조직학적진단명 코드 설명	0=아니오, 1=예	관찰입력 정보
5	암등록	Neuroendocrin e carcinoma	조직학적진단명 코드 설명	0=아니오, 1=예	관찰입력 정보
6	암등록	squamous cell carcinoma	조직학적진단명 코드 설명	0=아니오, 1=예	관찰입력 정보
7	암등록	Neoplasm malignant	조직학적진단명 코드 설명	0=아니오, 1=예	관찰입력 정보
8	암등록	Tis	병기STAGE	0=아니오, 1=예	관찰입력 정보
9	암등록	T1	병기STAGE	0=아니오, 1=예	관찰입력 정보
10	암등록	T1a	병기STAGE	0=아니오, 1=예	관찰입력 정보

11	암등록	T1b	병기STAGE	0=아니오, 1=예	관찰입력 정보
12	암등록	T1c	병기STAGE	0=아니오, 1=예	관찰입력 정보
13	암등록	T2	병기STAGE	0=아니오, 1=예	관찰입력 정보
14	암등록	T2a	병기STAGE	0=아니오, 1=예	관찰입력 정보
15	암등록	T2b	병기STAGE	0=아니오, 1=예	관찰입력 정보
16	암등록	T2C	병기STAGE	0=아니오, 1=예	관찰입력 정보
17	암등록	T3	병기STAGE	0=아니오, 1=예	관찰입력 정보
18	암등록	T3a	병기STAGE	0=아니오, 1=예	관찰입력 정보
19	암등록	T3b	병기STAGE	0=아니오, 1=예	관찰입력 정보
20	암등록	T4	병기STAGE	0=아니오, 1=예	관찰입력 정보
21	암등록	T4a	병기STAGE	0=아니오, 1=예	관찰입력 정보
22	암등록	T4b	병기STAGE	0=아니오, 1=예	관찰입력 정보

23	암등록	N1	병기STAGE	0=아니오, 1=예	관찰입력 정보
24	암등록	N1a	병기STAGE	0=아니오, 1=예	관찰입력 정보
25	암등록	N1b	병기STAGE	0=아니오, 1=예	관찰입력 정보
26	암등록	N1c	병기STAGE	0=아니오, 1=예	관찰입력 정보
27	암등록	N2	병기STAGE	0=아니오, 1=예	관찰입력 정보
28	암등록	N2a	병기STAGE	0=아니오, 1=예	관찰입력 정보
29	암등록	N2b	병기STAGE	0=아니오, 1=예	관찰입력 정보
30	암등록	N2c	병기STAGE	0=아니오, 1=예	관찰입력 정보
31	암등록	N3	병기STAGE	0=아니오, 1=예	관찰입력 정보
32	암등록	N3a	병기STAGE	0=아니오, 1=예	관찰입력 정보
33	암등록	N3b	병기STAGE	0=아니오, 1=예	관찰입력 정보
34	암등록	M1	병기STAGE	0=아니오, 1=예	관찰입력 정보

35	암등록	M1a	병기STAGE	1=아니오, 1=예	관찰입력 정보
36	암등록	M1b	병기STAGE	0=아니오, 1=예	관찰입력 정보
37	암등록	M1c	병기STAGE	0=아니오, 1=예	관찰입력 정보
38	건강정보	Type of Drink	음주종류	1=맥주, 2=소주, 3=양주, 99=기타	관찰입력 정보
39	건강정보	Smoke	흡연여부	0=비흡연, 1=현재흡연, 2=과거흡연	관찰입력 정보
40	신체계측 정보	Height	신장값	170.1	관찰입력 정보
41	신체계측 정보	Weight	체중측정값	64.5	관찰입력 정보
42	면역병리	EGFR	면역병리EGFR검사코드/명	1=negative, 2=positive, 99= 해당사항 없음	관찰입력 정보
43	분자병리	MSI	분자병리MSI검사결과코드/명	1=stable, 2=low, 3=high, 99= 해당사항 없음	관찰입력 정보
44	분자병리	KRASMUTATION_EXON2	분자병리KRASMUTATION_EXON2검사결과코드/명	1= not detected, 2=detected, 99 = 해당사항없음	관찰입력 정보
45	분자병리	KRASMUTATION	분자병리KRASMUTATION검사결과코드/명	1= not detected, 2=detected, 99 = 해당사항없음	관찰입력 정보
46	분자병리	NRASMUTATION	분자병리NRASMUTATION검사결과코드/명	1= not detected, 2=detected, 99 = 해당사항없음	관찰입력 정보

47	분자병리	BRAF_MUTATION	분자병리BRAF_MUTATION검사결과코드/명	1= not detected, 2=detected, 99 = 해당사항없음	관찰입력 정보
48	수술여부	Operation	대장암 수술 여부	0=아니오, 1=예	관찰입력 정보
49	항암제 치료	Chemotherapy	항암제 치료 여부	0=아니오, 1=예	관찰입력 정보
50	방사선 치료	Radiation Therapy	방사선치료 여부	0=아니오, 1=예	관찰입력 정보
51	기본정보	Death	사망여부	0=아니오, 1=예	관찰입력 정보
52	기본정보	Survival period	암진단후생존일수	267 (days)	관찰입력 정보

○ 폐암 합성데이터 코드북

NO.	중분류	변수명	변수 설명	변수값(코드) 설명 (99=모름/기타/미측정)	데이터 유형
0	기본정보	AGE	진단시연령	53	관찰입력 정보
1	암등록	Adenocarcinoma	조직학적진단명 코드 설명	0=아니오, 1=예	관찰입력 정보
2	암등록	Large cell carcinoma	조직학적진단명 코드 설명	0=아니오, 1=예	관찰입력 정보
3	암등록	Squamous cell carcinoma	조직학적진단명 코드 설명	0=아니오, 1=예	관찰입력 정보
4	암등록	TX	병기STAGE	0=아니오, 1=예	관찰입력 정보
5	암등록	T0	병기STAGE	0=아니오, 1=예	관찰입력 정보
6	암등록	T1	병기STAGE	0=아니오, 1=예	관찰입력 정보
7	암등록	T1a	병기STAGE	0=아니오, 1=예	관찰입력 정보
8	암등록	T1b	병기STAGE	0=아니오, 1=예	관찰입력 정보
9	암등록	T1c	병기STAGE	0=아니오, 1=예	관찰입력 정보
10	암등록	T2	병기STAGE	0=아니오, 1=예	관찰입력 정보

11	암등록	T2a	병기STAGE	0=아니오, 1=예	관찰입력 정보
12	암등록	T2b	병기STAGE	0=아니오, 1=예	관찰입력 정보
13	암등록	T3	병기STAGE	0=아니오, 1=예	관찰입력 정보
14	암등록	T4	병기STAGE	0=아니오, 1=예	관찰입력 정보
15	암등록	N1	병기STAGE	0=아니오, 1=예	관찰입력 정보
16	암등록	N2	병기STAGE	0=아니오, 1=예	관찰입력 정보
17	암등록	N3	병기STAGE	0=아니오, 1=예	관찰입력 정보
18	암등록	M1a	병기STAGE	0=아니오, 1=예	관찰입력 정보
19	암등록	M1b	병기STAGE	0=아니오, 1=예	관찰입력 정보
20	암등록	M1c	병기STAGE	0=아니오, 1=예	관찰입력 정보
21	건강정보	Type of Drink	음주종류	1=맥주, 2=소주, 3=양주, 99=기타	관찰입력 정보
22	건강정보	Smoke	흡연여부	0=비흡연, 1=현재흡연, 2=과거흡연	관찰입력 정보

23	신체계측 정보	Height	신장값	151.8	관찰입력 정보
24	신체계측 정보	Weight	체중측정값	73.8	관찰입력 정보
25	폐기능검사	FEV1_FVC_P	FEV 검사 값	87	관찰입력 정보
26	폐기능검사	DLCO_VA_P	DLCO 검사 값	102	관찰입력 정보
27	분자병리	EGFR mutation Detection	EGFR mutation 발견 여부	0=아니오, 1=예, 99 = 해당사항없음	관찰입력 정보
28	수술여부	Operation	수술여부	0=아니오, 1=예	관찰입력 정보
29	항암제 치료	Chemotherapy	항암치료여부	0=아니오, 1=예	관찰입력 정보
30	방사선 치료	Radiation Therapy	방사선치료여부	0=아니오, 1=예	관찰입력 정보
31	기본정보	Death	사망여부	0=아니오, 1=예	관찰입력 정보
32	기본정보	Survival period	암진단후생존일수	157 (days)	관찰입력 정보

□ 데이터 구축 과정

○ 데이터 구축 과정은 헬스케어 분야 특성상 공개되는 데이터가 개인의 의료 정보가 포함된 민감정보인 관계로 개인정보보호법을 위반하지 않는 절차를 철저히 준수하여 진행하였다.

○ '21년에 IRB 승인을 받고, 안전한 폐쇄분석환경에서 해당 데이터를 분석하여 가상의 데이터인 합성 데이터를 생성하였음

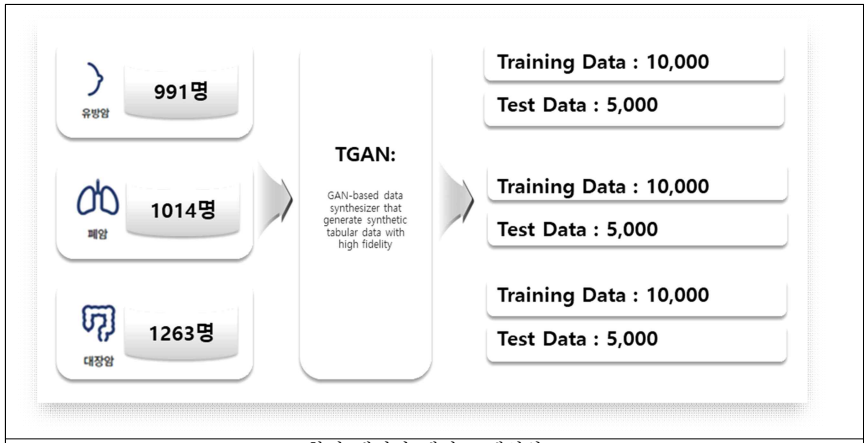

합성 데이터 생성 프레임워크

□ 데이터 품질 검증

○ 폐암·대장암·유방암 합성 데이터 품질 점검은 원본데이터와 합성 데이터의 분포 비교를 통해 시행되었으며 유사한 분포를 보임

유방암 원본데이터 vs 합성데이터 분포 비교

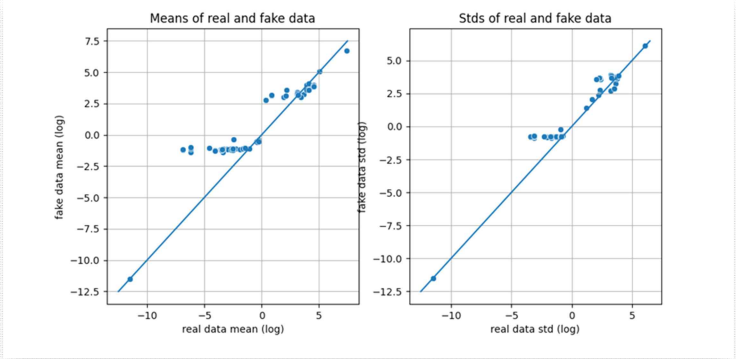

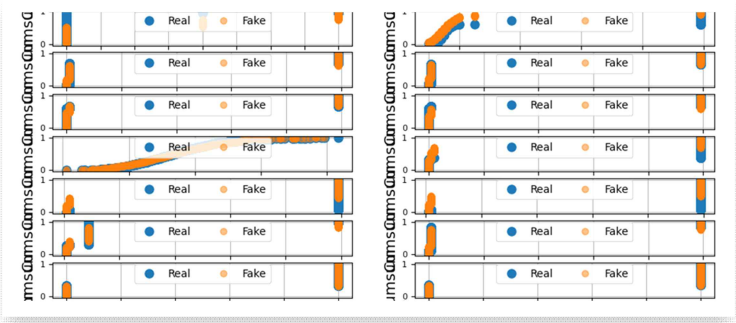

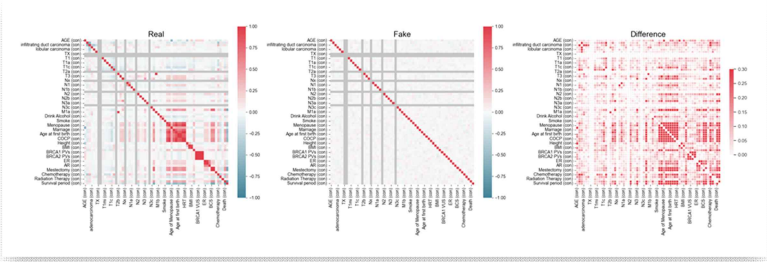

폐암 원본데이터 vs 합성데이터 분포 비교

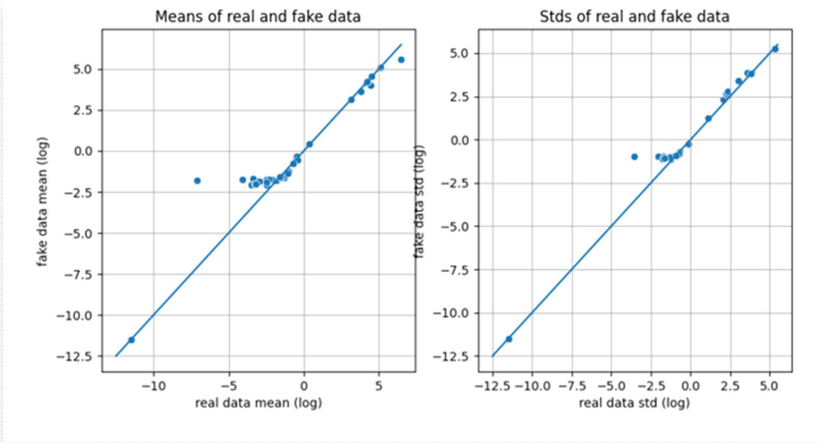

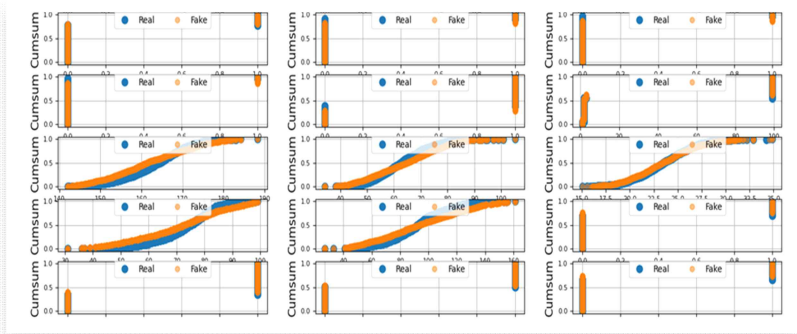

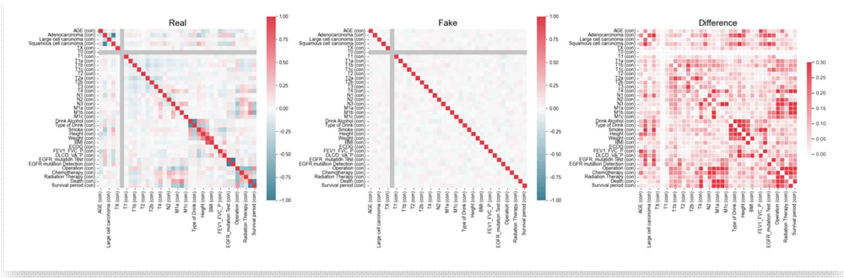

대장암 원본데이터 vs 합성데이터 분포 비교

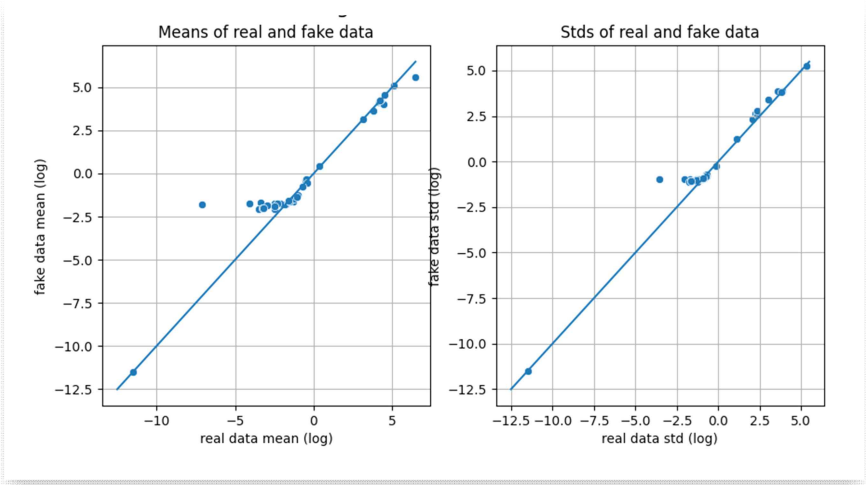

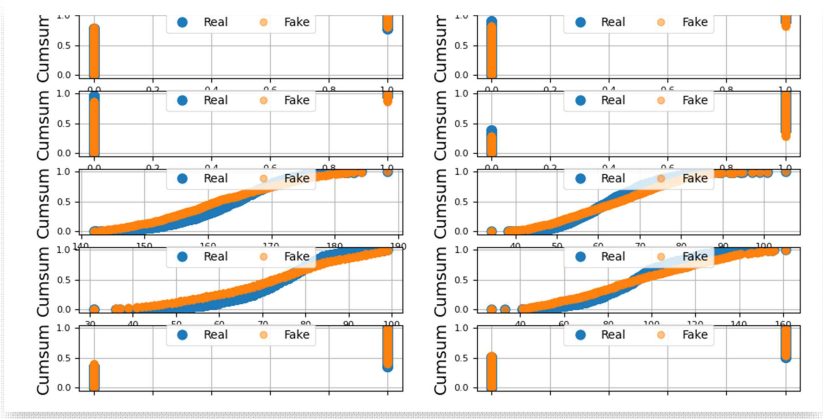

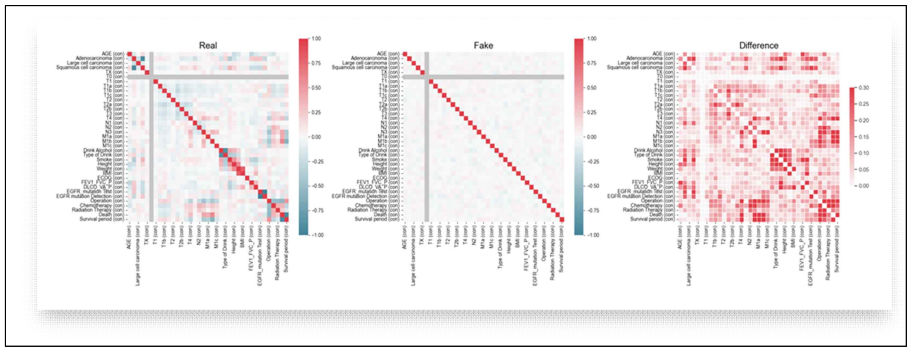

□ 데이터 관리 담당자

○ 수행기관 : 국립암센터

- 담당자 : 류광선 선임연구원
- 전　화 : 031-920-0652
- 이메일 : niceplay13@ncc.re.kr